AsmaBRAZI_Inpainting

May 11, 2019

Import de librairies et fonctions

In [1]:
```
import numpy as np
import random
import matplotlib.pyplot as plt
from matplotlib import cm
from numpy import linalg as LA
import copy
import sklearn.feature_extraction.image as sk_fe
from sklearn import (manifold, datasets, decomposition, ensemble,
                     discriminant_analysis, random_projection)
from sklearn.linear_model import (LinearRegression,Ridge, RidgeClassifierCV,
                                  LassoCV, Lasso,Ridge)
from sklearn.manifold import Isomap
import matplotlib.colors as colors
from sklearn.decomposition import MiniBatchDictionaryLearning
from sklearn.feature_extraction.image import extract_patches_2d
from utils import *
import warnings
warnings.filterwarnings("ignore", category=DeprecationWarning)
```

Partie I : Régression Linéaire, Régression Ridge et LASSO
Analyse de la base de données

In [2]:
```
datax_train, datay_train = load_usps("../res/USPS/USPS_train.txt")
datax_test, datay_test = load_usps("../res/USPS/USPS_test.txt")
```

In [3]:
```
fig, axe = plt.subplots(4, 6, subplot_kw=dict(xticks=[], yticks=[]))
for i in range(len(axe.flat)):
    (axe.flat)[i].imshow(datax_train[i].reshape(16, 16), cmap='gray_r')
```

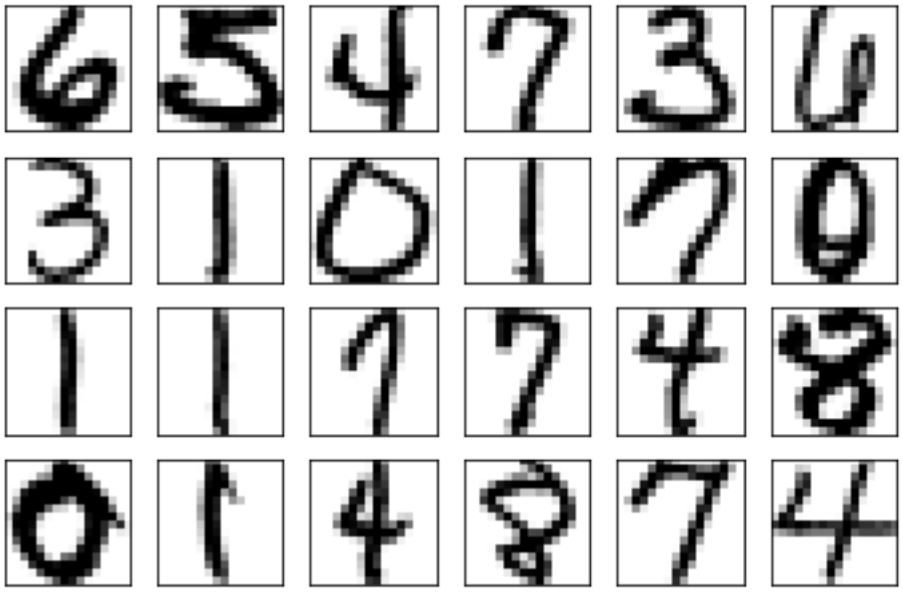

Nous souhaitons représenter ces données --> reduction de dimension https://prateekvjoshi.com/2014/06/21/what-is-manifold-learning/ 1/How do we reduce the dimensionality? 2/What exactly is manifold learning?

```
In [4]: # Projection des données en 2 dimensions
        model = Isomap(n_components=2)
        projection = model.fit_transform(datax_train[0:1500,:])

        # Affichage
        plt.figure(figsize=(8,6))
        plt.scatter(projection[:, 0], projection[:, 1], s=10, c=datay_train[0:1500], cmap=plt.
        plt.colorbar(ticks=range(10))
        plt.clim(-0.5, 9.5)
```

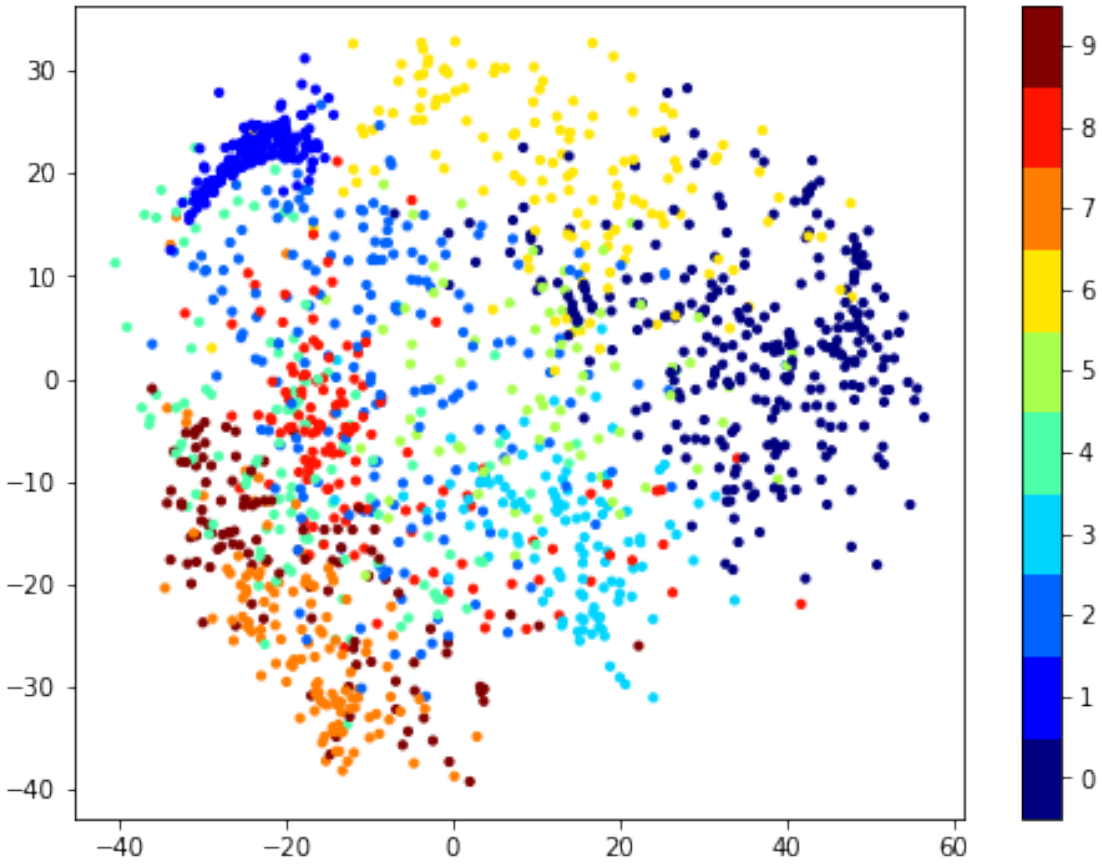

Dans la figure ci-dessus, nous avons projeté les données en deux dimensions. Cette représentation nous permet facilement d'analyser les données et de voir visualement les données qui sembleraient corrélées.

Nous pouvons remarquer que les distributions du chiffre 6 et 7 sont très éloignées. Alors, nous concluons que les chiffres 6 et 7 ne possèdent pas les mêmes caractéristques. Pour préciser, nous dirons que les écritures manuscrites de ces deux chiffres est très différente.

Plus loin, nous considérons les chiffres 3 et 8. Les distributions de ces chiffres sont confondues. Pour interpréter ce résutlat, nous pouvons imaginer que l'écriture manuscrite du chiffre 3 représente la moitité de celle du chiffre 8 de façon verticale. D'où la forte corrélation qui existe entre les chiffres 3 et 8.

Expérimentations

```
In [5]: trainx6_9, trainy6_9 =filter_oneVsone(datax_train, datay_train, 6,9)
        testx6_9, testy6_9 = filter_oneVsone(datax_test, datay_test, 6,9)

In [6]: def sklearn_model(trainx,trainy,testx,testy,model,alpha=0,max_iter=10000):
            myModel=model()
            myModel.fit(trainx,trainy)
            myModel_w=myModel.coef_
```

```
    testy_predicted = myModel.predict(testx)
    sc=score(testy,testy_predicted)
    return myModel_w,sc
```

0.0.1 Regression linéaire

```
In [7]: linear_w,linear_sc=sklearn_model(trainx6_9, trainy6_9,testx6_9, testy6_9,LinearRegressi
        print("Regression linéaire")
        print("Score en test: {:.3f}".format(linear_sc))
```

```
Regression linéaire
Score en test: 0.500
```

0.0.2 Regression ridge

```
In [8]: ridge_w,ridge_sc=sklearn_model(trainx6_9, trainy6_9,testx6_9, testy6_9,Ridge,alpha=0.0
        print("Regression ridge")
        print("Score en test: {:.3f}".format(ridge_sc))
```

```
Regression ridge
Score en test: 0.500
```

0.0.3 Algorithme du LASSO

```
In [9]: lasso_w,lasso_sc=sklearn_model(trainx6_9, trainy6_9,testx6_9, testy6_9,Lasso,alpha=1e-
        print("Algorithme du LASSO")
        print("Score en test: {:.3f}".format(lasso_sc))
```

```
Algorithme du LASSO
Score en test: 0.490
```

0.0.4 Effets du paramètre sur le vecteur de poids W

Nous allons entrainer nos modèles: Ridge regression et Lasso sur les données limitées aux chiffres 6 et 9. Dans cette expérience, nous allons varier les valeurs du paramètre afin de voir son effet sur le vecteur des poids W.

```
In [10]: alphas=[1e-9,1e-8,1e-7,1e-6,1e-5,1e-4,1e-3,1e-2,1e-1,1]
         count0_rid=[]
         ridge_ws=[]
         for alp in alphas:
             l=Ridge(alpha=alp,max_iter=50000)
             l.fit(trainx6_9,trainy6_9)
             rid_w=l.coef_
             testy_predicted = l.predict(testx6_9)
             sc=score(testy6_9,testy_predicted)
```

```
        count0_rid.append(np.count_nonzero(rid_w))
        ridge_ws.append(LA.norm(rid_w))
    count0_lasso=[]
    lasso_ws=[]
    for alp in alphas:
        l=Lasso(alpha=alp,max_iter=50000)
        l.fit(trainx6_9,trainy6_9)
        lasso_w=l.coef_
        testy_predicted = l.predict(testx6_9)
        sc=score(testy6_9,testy_predicted)
        count0_lasso.append(np.count_nonzero(lasso_w))
        lasso_ws.append(LA.norm(lasso_w))
```

In [11]:
```
plt.plot(ridge_ws,label='ridge')
plt.plot(lasso_ws,label='lasso')
plt.xlabel('alpha')
plt.ylabel('poids')
plt.title('Les poids wi en fonction de alpha')
plt.axis('tight')
plt.legend()
plt.show()
```

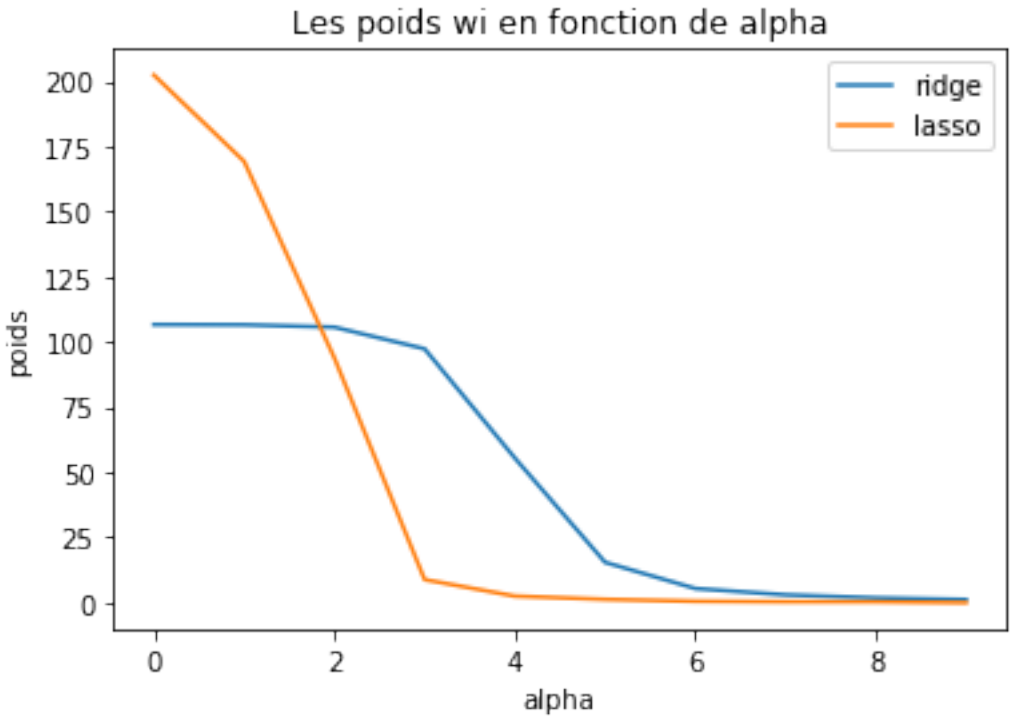

In [12]:
```
ax = plt.gca()
ax.plot(alphas, lasso_ws)
```

```
ax.set_xscale('log')
plt.xlabel('alpha')
plt.ylabel('weights')
plt.title('Ridge coefficients as a function of the regularization')
plt.axis('tight')
plt.show()
```

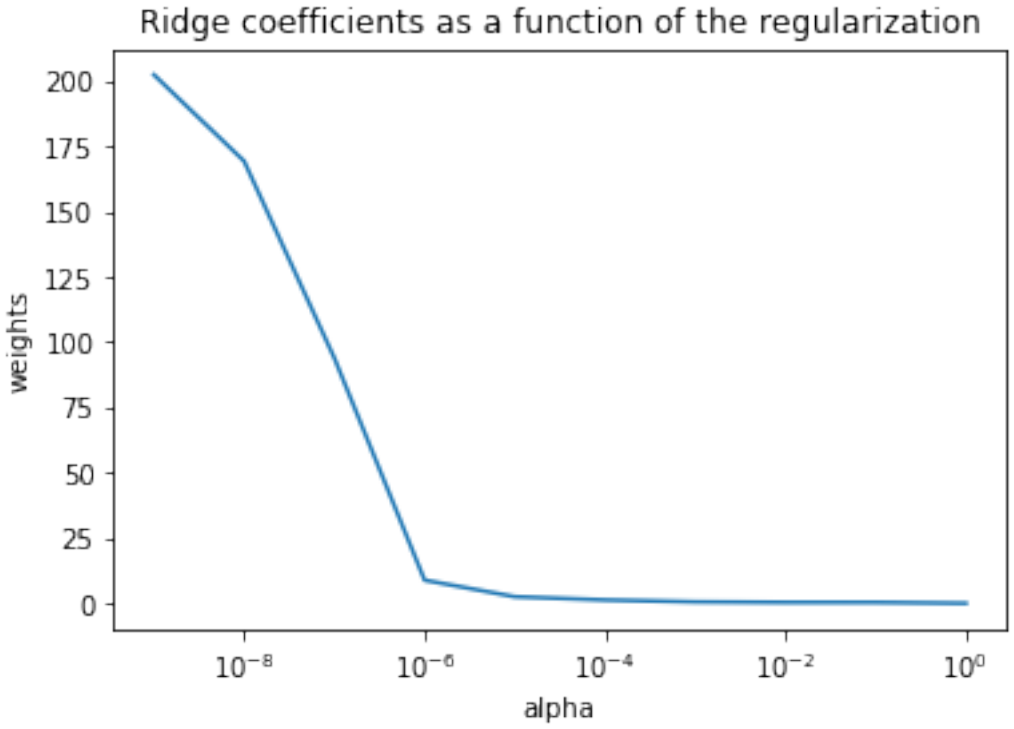

In [13]:
```
plt.plot(alphas,count0_rid,label='ridge')
plt.plot(alphas,count0_lasso,label='lasso')
plt.xlabel('alpha')
plt.ylabel('poids')
plt.title('Ridge coefficients as a function of the regularization')
plt.legend()
plt.title("Le nombre de composantes non nulles en fonction du paramètre ")
plt.show()
```

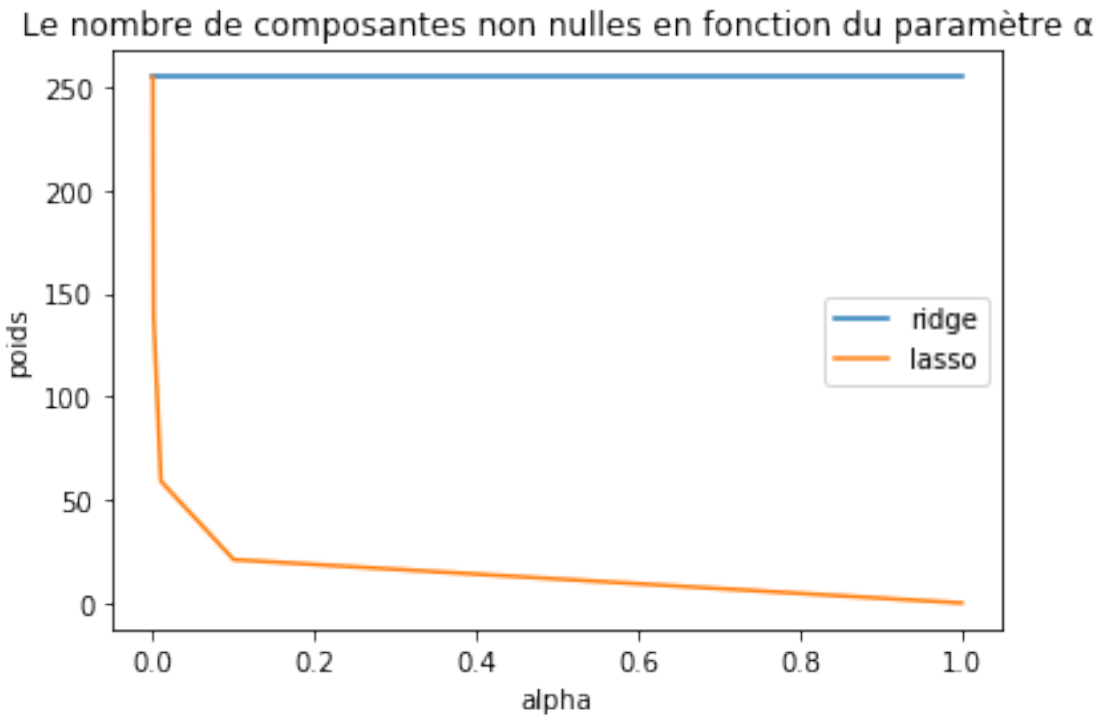

À partir de la figure ci-dessus, pourrait faire partie de trois classes: - = 0: dans ce cas, nous retourvons la regréssion linéaire. - --> : dans ce cas, il y a une très grande restriction sur la valeur des poids. Nous remarsuons que les poids s'annulent. Ceci est dû à la pondération infinie sur le carré des poids. - 0 < < : ceci représente le cas où les poids ne sont pas nuls.

```
In [14]: rid_w1,ridge_sc=sklearn_model(trainx6_9, trainy6_9,testx6_9, testy6_9,Ridge,alpha=0.0
         rid_w2,ridge_sc=sklearn_model(trainx6_9, trainy6_9,testx6_9, testy6_9,Ridge,alpha=0.9
```

```
In [15]: fig=plt.figure()
         fig.add_subplot(1, 2, 1)
         plt.title("Poids avec alpha=0.0001")
         plt.imshow(rid_w1.reshape(16,16),cmap='cool')
         fig.add_subplot(1, 2, 2)
         plt.title("Poids avec alpha=0.9")
         plt.imshow(rid_w2.reshape(16,16),cmap='cool')
         plt.show()
```

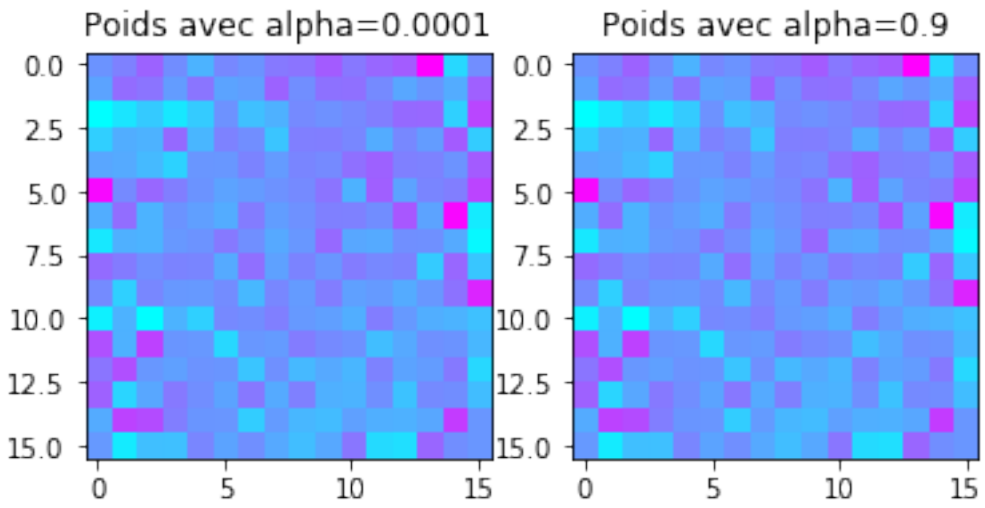

Partie II : LASSO et Inpainting

L'inpainting d'image consiste à reconstituer les parties manquantes d'une image de sorte que les régions restaurées soient led plus naturelles. Cette technique est souvent utilisée pour supprimer des objets indésirables d'une image ou pour restaurer des parties endommagées de vieilles photos.

Dans cette deuxième partie du projet, nous partons d'une image complète. Puis, nous allons bruiter cette image de façon à perdre des parties de l'images (pixel ou patch). Ensuite, nous allons essayer de restaurer ces parties manquantes en utilisant le Lasso.

Hypothèse de l'énoncé: nous allons considérer qu'une grande partie de l'image n'a pas de pixels manquants.

```
In [16]: im_rgb,im_hsv,im_hsv_norm=read_im("../res/lena.jpg")
         fig=plt.figure(figsize=(20, 8))
         fig.add_subplot(1, 3, 1)
         plt.title("Image en RGB")
         plt.imshow(im_rgb)
         fig.add_subplot(1, 3, 2)
         plt.title("Image en HSV")
         plt.imshow(im_hsv)
         fig.add_subplot(1, 3, 3)
         plt.title("Image en HSV normalisée")
         plt.imshow(im_hsv_norm)

Clipping input data to the valid range for imshow with RGB data ([0..1] for floats or [0..255]

Out[16]: <matplotlib.image.AxesImage at 0x7f8f1cec6668>
```

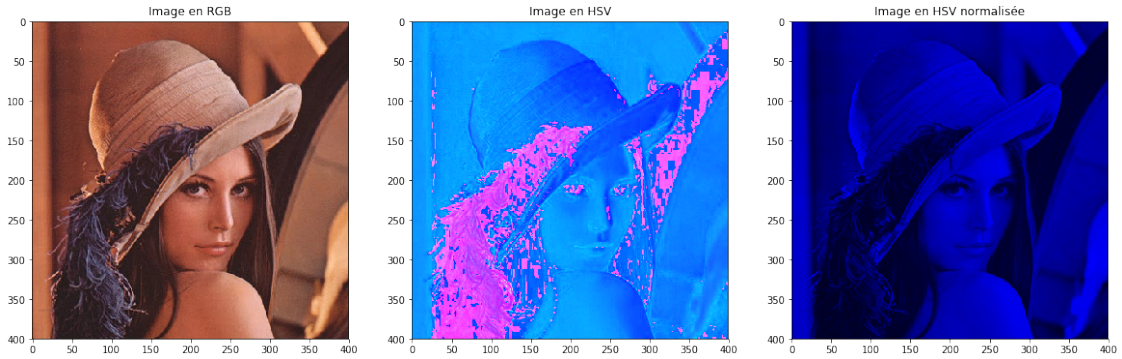

Nous allons commencer par étudier l'image de Léna et effectuer dessus des opérations de bruitage. Puis, nous allons tester l'efficacité des implémentées sur d'autres instances.

Test sur un dictionnaire issu de l'image complète non bruitée Tout d'abord, nous allons tester sur l'image originale sans la bruiter

```
In [17]: step=20
         h=40
         patches=get_patches(im_rgb,step,h)
         patches_comp=getPatches_comp(patches)
         data_train=build_data_train(im_rgb,patches_comp,step,h)
         model = Lasso(max_iter=2000)
         model.fit(data_train[0],data_train[1])
         new_img=reconstruct_im(model,im_rgb,h )
         fig=plt.figure(figsize=(10, 8))
         fig.add_subplot(1, 2, 1)
         plt.title("Image originale")
         plt.imshow(normalize(im_rgb))
         fig.add_subplot(1, 2, 2)
         plt.title("Image reconstruite")
         plt.imshow(normalize(new_img))
         plt.show()
```

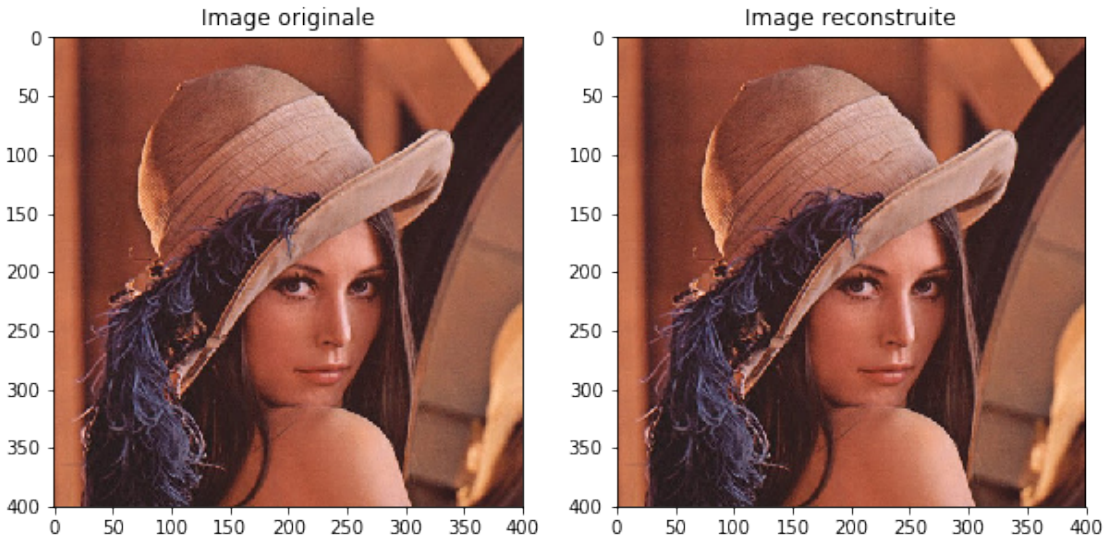


```
In [18]: plt.imshow(model.coef_.reshape((117,123)))
         plt.title("Matrice des poids")
         plt.show()
```

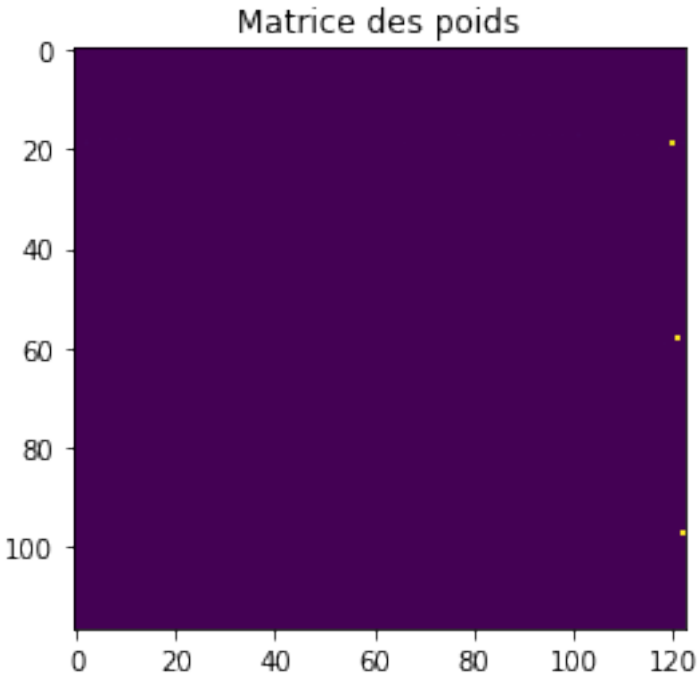

Nous remarquons que la matrice des poids n'est pas tout à fait à nul, comme on devait s'y attendait. Or, nous remarquons quelques points jaunes sur la matrice. Nous pensons que ceci est

dû au choix de la valeur de bruit à rajouter dans l'image, soit de (253,253,253). Donc, l'algorithme l'avait considée comme du bruit. Par conséquent, il a cherché à compléter le pixel portant cette valeur.

Test sur un dictionnaire issu de l'image complète bruitée Maintenant, nous allons bruiter l'image de Léna avec un pourcentage de 20%. Nous commençons avec un petit pourcentage pusique l'énoncé exige qu'une grande partie de l'image soit complète.

```
In [19]: step=20
         h=20
         image_noisy=noise(im_rgb,0.2)
         patches=get_patches(image_noisy,step,h)
         patches_comp=getPatches_comp(patches)
         data_train=build_data_train(image_noisy,patches_comp,step,h)
         model = Lasso(max_iter=2000)
         model.fit(data_train[0],data_train[1])
         new_img=reconstruct_im(model,image_noisy,h )
         fig=plt.figure(figsize=(20, 8))
         fig.add_subplot(1, 3, 1)
         plt.title("Image originale")
         plt.imshow(normalize(im_rgb))
         fig.add_subplot(1, 3, 2)
         plt.title("Image bruitée")
         plt.imshow(normalize(image_noisy))
         fig.add_subplot(1, 3, 3)
         plt.title("Image reconstruite")
         plt.imshow(normalize(new_img))
         plt.show()
```

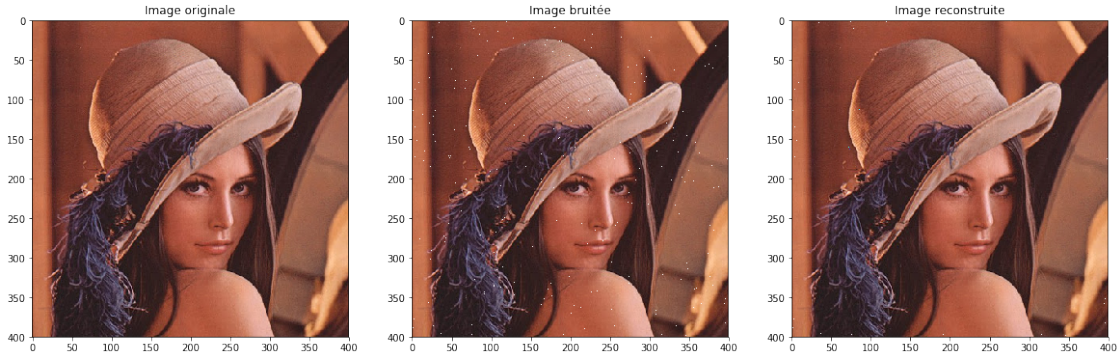

Nous constatons que l'algorithme a atténué une très grande majorité du bruit rajouté. Sauf, pour quelques pixels sir les bordures.

Test en particulier sur un patch sans bruit Dans cette partie, nous allons étudier particulièrement les patchs. Nous allons prendre un patch de l'image de Léna, le bruiter et analyser les

résultats obtenus. Nous avons choisi un patch qui contient le plus de contours, de détails et de changement de couleurs.

```
In [20]: patch=get_patch(200,200,200,im_rgb)
         step=20
         h=10
         patches=get_patches(patch,20,10)
         patches_comp=getPatches_comp(patches)
         data_train=build_data_train(image_noisy,patches_comp,step,h)
         model = Lasso(max_iter=3000)
         model.fit(data_train[0],data_train[1])
         new_img=reconstruct_im(model,patch,10 )
         fig=plt.figure(figsize=(10, 8))
         fig.add_subplot(1, 2, 1)
         plt.title("Image originale")
         plt.imshow(patch)
         fig.add_subplot(1, 2, 2)
         plt.title("Image reconstruite")
         plt.imshow(new_img)
         plt.show()
```

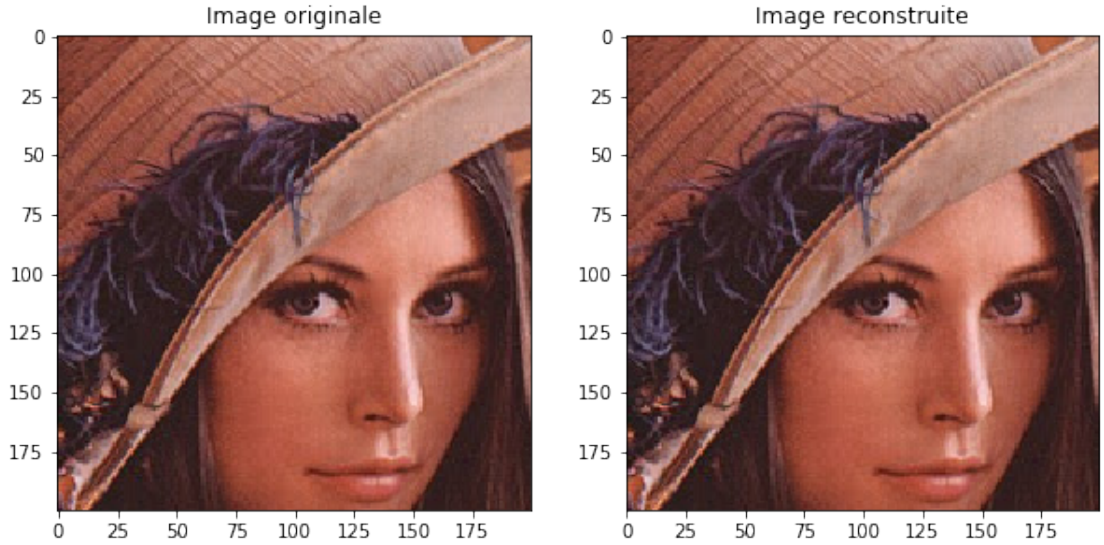

Test en particulier sur un patch avec du bruit Nous allons effectuer un bruit de 90%, dans le but de pousser la méthode à sa limite.

```
In [21]: step=4
         h=4
         patch_noisy=noise(patch,0.9)
         patches=get_patches(patch_noisy,step,h)
```

```
patches_comp=getPatches_comp(patches)
data_train=build_data_train(patch_noisy,patches_comp,step,h)
model = Lasso()
model.fit(data_train[0],data_train[1])
new_img=reconstruct_im(model,patch_noisy,h )
fig=plt.figure(figsize=(10, 8))
fig=plt.figure(figsize=(20, 8))
fig.add_subplot(1, 3, 1)
plt.title("Image originale")
plt.imshow(normalize(patch))
fig.add_subplot(1, 3, 2)
plt.title("Image bruitée")
plt.imshow(normalize(patch_noisy))
fig.add_subplot(1, 3, 3)
plt.title("Image reconstruite")
plt.imshow(normalize(new_img))
plt.show()
```

```
<Figure size 720x576 with 0 Axes>
```

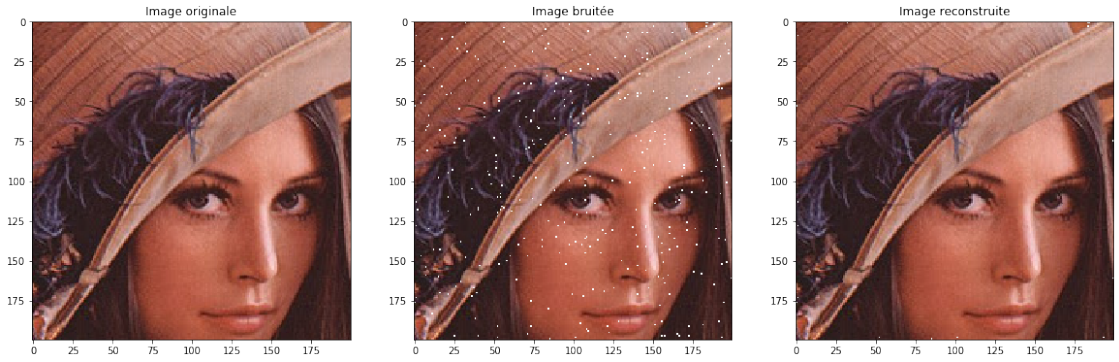

Nous avons obtenu un résultat assez satisfaisant, mis à part pour quelques pixels sur les bordues. Ce résultat a été obtenu en fixant le step et la fenêtre à 4.

Dans ce cas, la petite fenêtre était le meilleur choix à considérer, car comme l'image contient beaucoup de détails une grande fenêtre pourrait envelopper des pixels indésirables. Ces pixels indésirables pourraient appartenir par exemple à la partie des cheveux, pendant que nous cherchons à prédire les pixels au niveau du chapeau.

Le step fixé à 4 permet une meilleure précision.

Test en particulier sur une image avec un patch manquant Maintenant,nous allons supprimer toute une partie entière de l'image de Léna et analyser l'efficacité de la méthode développée.

```
In [22]: image=delete_rect(im_rgb,150,150,20,20)
         step=20
         h=40
```

```
patches=get_patches(image,step,h)
patches_comp=getPatches_comp(patches)
data_train=build_data_train(image,patches_comp,step,h)
model = Lasso(max_iter=2000)
model.fit(data_train[0],data_train[1])
new_img=reconstruct_im(model,image,h )
fig=plt.figure(figsize=(20, 8))
fig.add_subplot(1, 3, 1)
plt.title("Image originale")
plt.imshow(normalize(im_rgb))
fig.add_subplot(1, 3, 2)
plt.title("Image bruitée")
plt.imshow(normalize(image))
fig.add_subplot(1, 3, 3)
plt.title("Image reconstruite")
plt.imshow(normalize(new_img))
plt.show()
```

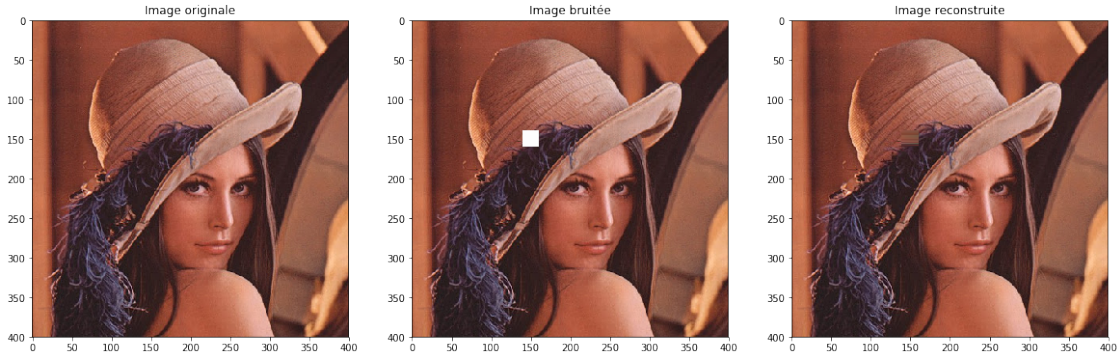

À ce stade, nous remarqons une reconstruction de l'image pas très satisfaisante. En particulier, la partie du chapeau à été plus ou moins bien reproduite. Or, nous remarquons que les pixels manquants à la partie du des cheveux ont pris la même couleur du chapeau.

Cette reconstruction nous montre que l'ordre dans lequel on remplit notre image possède un très grand impact sur le résultat. Ceci est dû au fait que les pixels au niveau du chapeau se remplissent avant les pixels au niveau du cheveux. Donc, au remplissage des pixels au niveau des cheveux, le patch considéré sur ces patchs est fortement influencé par les pixels reconsitués du chapeau.

Proposition d'une heuristique intelligente Dans cette partie, nous proposons une heurstique qui permetterait de remplir de manière plus intelligente que la méthode précédente et de considérer l'ordre dans lequel les pixels doivent se remplir:

1/ Détecter la présence d'un patch manquant M.

2/ À chaque itération remplir les bordures du patch en fonction des pixels environnants.

Critère d'arrêt: lorsque l'on arrive à remplir le centre de l'image.

Le remplissage des pixels sur les bordures s'effectue de cette marnière: 1/ Considérer un patch P avec comme centre le pixel p à prédire. 2/ Nous pouvons voir ce patch P sous forme de deux

"L" dont l'un à lenvers. Un premier "L" se situerait à l'intérieur du patch manquant M à prévoir. Ce "L" contient donc que des pixels manquants. Nous supprimons toutes ces valeurs manquantes de ce patch, sinon ça fausserait la prédiction. Nous gardons alors, uniquement les pixels vivants (non manquants).

Or, lorsque l'on supprime ces valeurs, la taille du patch change. Pour palier à ce problème, nous calculons la médiane des pixels vivants et nous complétons le patch P avec cette médiane jusqu'à atteindre sa taille de départ.

```
In [23]: image=delete_rect(im_rgb,150,150,40,40)
         step=40
         h=40
         patches=get_patches(image,step,h)
         patches_comp=getPatches_comp(patches)
         data_train=build_data_train(image,patches_comp,step,h)
         model = Lasso(max_iter=5000)
         model.fit(data_train[0],data_train[1])
         new_img=reconstruct_im_rec(model,image,h,150,150 )
         fig=plt.figure(figsize=(20, 8))
         fig.add_subplot(1, 3, 1)
         plt.title("Image originale")
         plt.imshow(normalize(im_rgb))
         fig.add_subplot(1, 3, 2)
         plt.title("Image bruitée")
         plt.imshow(normalize(image))
         fig.add_subplot(1, 3, 3)
         plt.title("Image reconstruite")
         plt.imshow(normalize(new_img))
         plt.show()
```

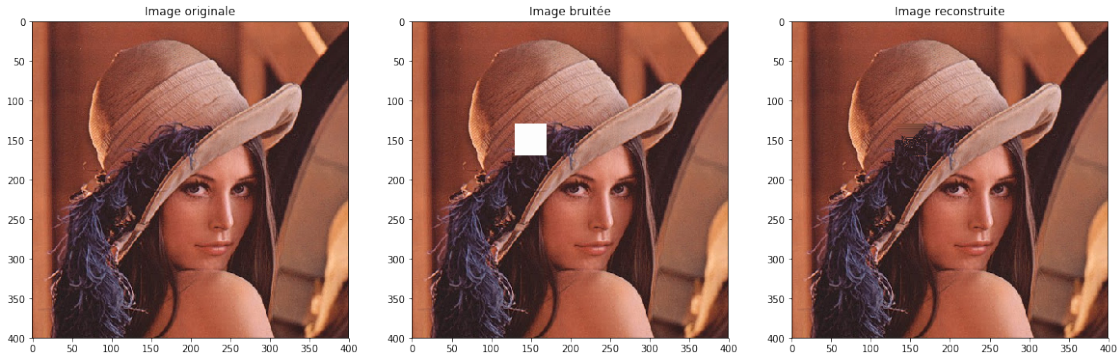

À présent, nous remarquons que le problème rencontré avec l'approche initiale à été reglé avec cette heuristique. Les pixels se situant sur la partie de cheveux sont bien restistués et de même pour les pixels au niveau du chapeau.

0.1 Expérimentations

Pour s'assurer de l'efficacité de notre heuristique développée, nous l'avons testés sur d'autres images pour voir comment est-ce que cette heuristique se comporte sous d'autres contraintes.

Nous avons obtenus les résultats suivants qui restent suffisamment acceptables:

```
In [24]: im_rgb,im_hsv,im_hsv_norm=read_im("../res/foret.jpg")
         image=delete_rect(im_rgb,150,150,80,80)
         step=80
         h=80
         patches=get_patches(image,step,h)
         patches_comp=getPatches_comp(patches)
         data_train=build_data_train(image,patches_comp,step,h)
         model = Lasso(max_iter=5000)
         model.fit(data_train[0],data_train[1])
         new_img=reconstruct_im_rec(model,image,h,150,150 )
         fig=plt.figure(figsize=(20, 8))
         fig.add_subplot(1, 3, 1)
         plt.title("Image originale")
         plt.imshow(normalize(im_rgb))
         fig.add_subplot(1, 3, 2)
         plt.title("Image bruitée")
         plt.imshow(normalize(image))
         fig.add_subplot(1, 3, 3)
         plt.title("Image reconstruite")
         plt.imshow(normalize(new_img))
         plt.show()
```

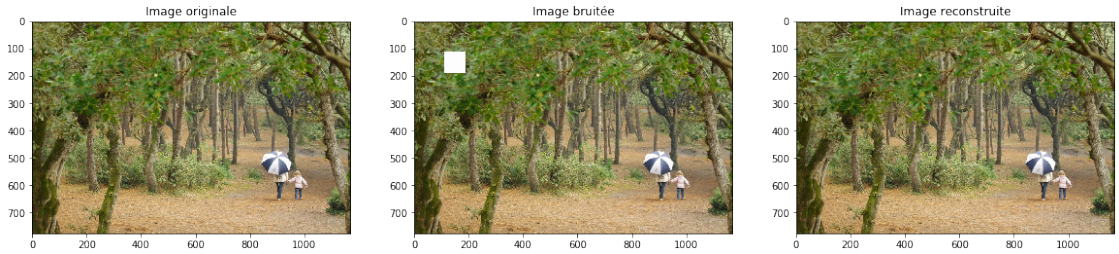


```
In [25]: im_rgb,im_hsv,im_hsv_norm=read_im("../res/plage.jpg")
         image=delete_rect(im_rgb,200,300,40,40)
         step=40
         h=40
         patches=get_patches(image,step,h)
         patches_comp=getPatches_comp(patches)
         data_train=build_data_train(image,patches_comp,step,h)
         model = Lasso(max_iter=5000)
         model.fit(data_train[0],data_train[1])
         new_img=reconstruct_im_rec(model,image,h,200,300)
         fig=plt.figure(figsize=(20, 8))
         fig.add_subplot(1, 3, 1)
         plt.title("Image originale")
```

```
plt.imshow(normalize(im_rgb))
fig.add_subplot(1, 3, 2)
plt.title("Image bruitée")
plt.imshow(normalize(image))
fig.add_subplot(1, 3, 3)
plt.title("Image reconstruite")
plt.imshow(normalize(new_img))
plt.show()
```

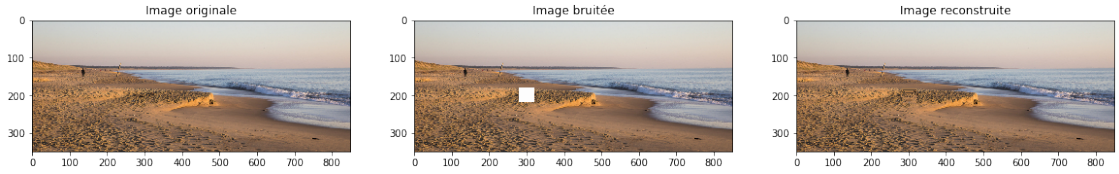

In [26]:
```
im_rgb,im_hsv,im_hsv_norm=read_im("../res/parapluie.jpg")
image=delete_rect(im_rgb,570,400,40,40)
step=40
h=40
patches=get_patches(image,step,h)
patches_comp=getPatches_comp(patches)
data_train=build_data_train(image,patches_comp,step,h)
model = Lasso(max_iter=5000)
model.fit(data_train[0],data_train[1])
new_img=reconstruct_im_rec(model,image,h,570,400)
fig=plt.figure(figsize=(20, 8))
fig.add_subplot(1, 3, 1)
plt.title("Image originale")
plt.imshow(normalize(im_rgb))
fig.add_subplot(1, 3, 2)
plt.title("Image bruitée")
plt.imshow(normalize(image))
fig.add_subplot(1, 3, 3)
plt.title("Image reconstruite")
plt.imshow(normalize(new_img))
plt.show()
```

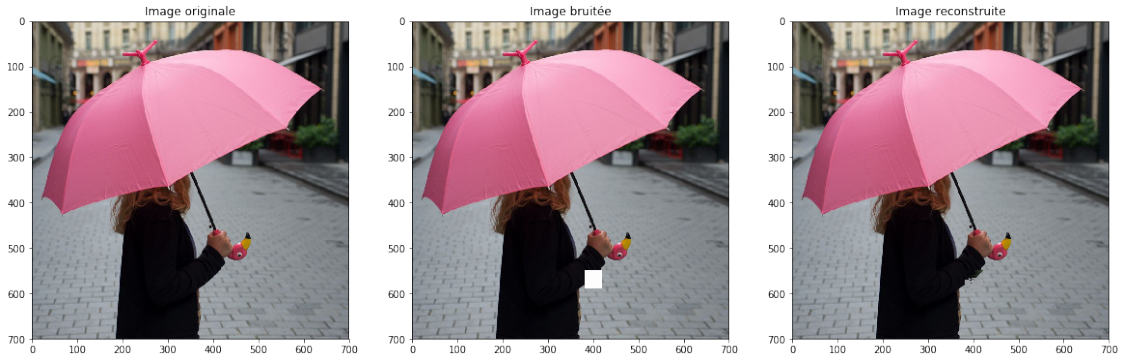

0.2 Conclusion

Cette heuristique développée pourrait avoir de meilleurs résultats si nous diminuons la taille de la fenêtre ou du step, et en effectuant le traitement sur une machine plus performante. Aussi, il pourrait être intéressant de coder 3 Lasso, chacun sur une dimension, au lieu de d'un seul comme dans notre cas.

Sources:

- https://towardsdatascience.com/image-inpainting-humans-vs-ai-48fc4bca7ecc